Limites na medição de emoções

Cauã De Martin · 29/10/2026 · Modelo BERTimbau multi-rótulo (6 emoções)

Resumo: com os dados em PT-BR disponíveis hoje, **nojo, medo e surpresa não são medidos de forma confiável**. No teste BRIGHTER PT-BR, o modelo encontra só 18% dos textos com nojo, 27% dos com medo e 25% dos com surpresa. Alegria, raiva e tristeza ficam com F1 entre 0,66 e 0,71. A maior parte do limite está nos dados, porque com outros dados o mesmo modelo mede essas emoções razoavelmente. Uma parte está no modelo: no mesmo teste, o melhor sistema do SemEval-2025 chegou a 0,683 de F1 macro, contra 0,505 do nosso.

1. O que o modelo mostra

Teste BRIGHTER PT-BR (2.226 textos de redes sociais, rotulados por humanos nativos), modelo atual:

Emoção	F1	IC 95%	Recall	Precisão	Exemplos no teste	Exemplos no treino
Alegria	0,71	0,68–0,74	83%	62%	555	581
Raiva	0,71	0,68–0,73	71%	70%	699	718
Tristeza	0,66	0,62–0,70	66%	67%	343	322
Medo	0,38	0,29–0,46	27%	66%	139	109
Surpresa	0,36	0,28–0,44	25%	60%	157	153
Nojo	0,21	0,11–0,31	18%	26%	71	75

Fonte: `models/metricas_emocoes.json`. Recall e precisão calculados a partir das matrizes de confusão por emoção. O IC do nojo vai de 0,11 a 0,31, largo demais para servir de métrica.

Mexer no treino ajudou pouco. O F1 de nojo no BRIGHTER foi de 0,06 (05/10) para 0,11 (20/10) e 0,21 (hoje), passando por pos_weight com raiz, peso 2 para o BRIGHTER e notas de LLM. Continua sendo o pior rótulo e com IC largo.

2. Para onde vão os erros

Pela matriz de coocorrência (linhas = emoção real, colunas = previsão), o modelo troca as emoções raras pelas frequentes:

- **Nojo:** dos 71 textos, 41 foram previstos como raiva e só 13 como nojo.
- **Medo:** dos 139 textos, 42 foram previstos como raiva, 24 como tristeza e 37 como medo.
- **Surpresa:** dos 157 textos, 57 foram previstos como raiva, 52 como alegria e 40 como surpresa.

Isso indica que, nesses textos, o sinal que separa essas emoções das vizinhas é fraco ou não aparece.

3. Quanto é limite dos dados

No teste GoEmotions-PT, o *mesmo* modelo tira 0,52 em nojo, 0,66 em medo e 0,68 em surpresa. As emoções são mensuráveis num conjunto e não no outro. Mas o GoEmotions-PT não resolve o problema do produto:

- foi traduzido por LLM a partir de comentários do Reddit em inglês;
- usa um mapeamento para Ekman mais amplo que o do nosso guia (por exemplo, *annoyance* entra em raiva);
- tem cerca de 30% de rótulos errados, segundo uma auditoria da Surge AI (ver seção 4).

O único corpus PT-BR nativo, aberto e com texto bruto que encontramos é o BRIGHTER, que tem 75 exemplos de nojo e 109 de medo no treino. O corpus de reviews de apps do Zenodo foi rejeitado porque o texto vem com stemming e os rótulos estão mapeados de forma errada.

4. O que a literatura diz

1. **Os rótulos dos datasets grandes têm ruído.** A Surge AI revisou 1.000 comentários do GoEmotions e julgou cerca de 30% dos rótulos errados, sobretudo em gírias, ironia e palavrões. É uma auditoria da própria empresa, não revisada por pares.
2. **Os datasets medem a emoção que o leitor percebe, não a que o autor sente.** O BRIGHTER rotula explicitamente "perceived emotions". Troiano, Padó e Klinger (2019) separam escritor e leitor justamente porque os dois divergem. Para um produto que quer saber o que o cliente sente, essa é uma diferença de construto, e mais dados não a resolvem.
3. **A concordância entre anotadores limita o teto.** Troiano et al. (2021) mostram que a concordância depende da intensidade e da confiança do anotador. Emoções raras e sutis em texto curto tendem a ficar na faixa de baixa concordância, e nenhum modelo passa do que os humanos concordam.
4. **Os dados vêm de outro domínio.** O BRIGHTER usa posts de redes sociais e o GoEmotions usa Reddit, e nenhum dos dois é atendimento. Num chat de suporte, medo e nojo aparecem pouco e de forma indireta.

5. Alguma solução detecta as seis bem no nosso escopo?

Não conhecemos nenhuma que funcione no nosso escopo: PT-BR, chat de atendimento, texto curto e as 6 emoções de Ekman. O melhor resultado público para PT-BR vem do mesmo dataset que usamos, e ele não é do nosso domínio.

Sistema (teste BRIGHTER PT-BR, Track A)	**F1 macro**
Melhor equipe do SemEval-2025 (PAI)	0,683
2º lugar (Heimerdinger)	0,625
Nosso modelo (BERTimbau)	**0,505**
Baseline RoBERTa da organização	0,426
Baseline de classe majoritária	0,243

Fonte: Muhammad et al. (2025), SemEval-2025 Task 11, Tabela 2. O paper não publica F1 por emoção, então não dá para dizer quanto o vencedor tirou em nojo e medo. A comparação supõe que o F1 macro da task e o nosso são calculados sobre as mesmas 6 emoções.

- **Estamos atrás do estado da arte.** A diferença para o vencedor é de 0,18 no F1 macro. Parte da fraqueza em nojo, medo e surpresa pode ser do nosso modelo, e não só dos dados.
- **Mesmo o vencedor fica longe do ideal.** 0,683 de F1 macro num conjunto de redes sociais não garante nada em conversas de atendimento.
- **LLM zero-shot** (já usado para gerar notas em `emocoes_llm`) não depende de ter 75 exemplos de nojo. Pode ir melhor nas classes raras, mas sem gabarito do nosso domínio não há como provar. O

problema de emoção percebida vs. sentida continua.

Caminhos realistas:

1. **Anotar dados do nosso atendimento:** algumas centenas de casos por emoção rara, com duas pessoas por texto para medir a concordância. É o único caminho que resolve de verdade.
2. **Juntar classes:** nojo entra em raiva (o modelo já confunde as duas), ou as duas viram uma classe só de "aversão/insatisfação".
3. **Exibir só as três confiáveis** e marcar medo e surpresa como experimentais.

6. Proposta

> Até termos dados anotados do nosso domínio, nojo, medo e surpresa não devem ser exibidos como métrica para o cliente. Alegria, raiva e tristeza podem ser exibidas.

- Manter as três emoções no modelo, mas só como sinal interno, sem aparecer no painel.
- Para reabrir a questão: anotar conversas reais de atendimento seguindo o `docs/emocoes/guia-anotacao.md`, com pelo menos 2 anotadores por texto, e medir a concordância antes de treinar.

Em aberto: não conferimos o kappa por emoção do BRIGHTER PT-BR. Se for baixo para nojo e medo, este é o argumento mais forte do documento, e vale buscar a tabela no apêndice do paper. Também vale ler o paper da equipe PAI para ver o F1 dela por emoção e quanto do ganho vem do modelo usado.

Fontes

- Muhammad et al. (2025). BRIGHTER: BRIdging the Gap in Human-Annotated Textual Emotion Recognition Datasets for 28 Languages. arxiv.org/abs/2502.11926
- Muhammad et al. (2025). SemEval-2025 Task 11: Bridging the Gap in Text-Based Emotion Detection. arxiv.org/abs/2503.07269
- Demszky et al. (2020). GoEmotions: A Dataset of Fine-Grained Emotions. arxiv.org/abs/2005.00547
- Surge AI (2022). 30% of Google's Reddit Emotions Dataset is Mislabeled. surgehq.ai
- Troiano, Padó e Klinger (2019). Crowdsourcing and Validating Event-focused Emotion Corpora for German and English. arxiv.org/abs/1905.13618
- Troiano, Padó e Klinger (2021). Emotion Ratings: How Intensity, Annotation Confidence and Agreements are Entangled. ims.uni-stuttgart.de
- Métricas internas: `models/metricas_emocoes.json`, `metricas_emocoes-0510.json`, `metricas_emocoes-2010.json`; fontes de dados: `docs/emocoes/fontes.md`.